최종보고서[요약서]

관리번호		동아리명	EIDOS
탐구주제	수열 변환 규칙을 학습하는 Transformer에서 Grokking의 경계와 지연을 정하는 요인		
학교급	고교		
요약문	□ 탐구배경 및 동기 ○ 일부 정답을 일부러 틀리게 바꾸어 AI를 학습시키자, 처음 보는 문제는 잘 맞히면서도 틀리게 배운 문제에는 외운 오답을 그대로 냈다. 규칙의 이해와 답의 암기가 한 AI 안에 함께 있었다. ○ AI는 학습 문제를 다 외운 뒤 한참 지나서야 처음 보는 문제까지 맞히기도 한다(Grokking). 본 탐구는 이를 위해 데이터가 몇 개 필요하고 시간이 얼마나 걸리는지를 미리 계산하고자 하였다. □ 탐구내용 및 과정 ○ 서로 다른 숫자 5개로 된 수열을 정해진 규칙(예: 각 숫자와 다음 숫자의 합)으로 바꾸는 과제를 작은 Transformer에 학습시키고, 조건을 바꾸며 약 4,700회 학습하였다. - 연구문제 0: 규칙을 익힌 AI는 왜 외운 오답을 계속 내는가? - 연구문제 1: 처음 보는 문제를 맞히려면 학습 데이터가 몇 개 필요한가? - 연구문제 2: 처음 보는 문제를 맞히기까지 걸리는 시간은 무엇으로 정해지는가? □ 탐구 결과 및 기대효과 ○ 필요한 데이터 수는 AI가 배워야 할 연산 표의 크기(칸 수 C)로 계산되었다($N_0 \approx 2.8 \times C^{0.76}$). 관계식에 따르면, 표가 4배 커지면 필요한 데이터는 약 2.9배가 된다. ○ 데이터를 넓게 보는 것보다 같은 칸을 여러 번 반복해서 보는 것이 학습을 앞당겼고, 이를 이용해 암기 이후 일반화까지의 추가 학습 단계 수를 실험 전에 예측하였다. ○ 규제(Weight Decay)가 약하면 규칙을 익힌 뒤에도 외운 오답이 남았지만, 알맞게 강하면 필요한 데이터를 거의 늘리지 않고도 외운 오답을 대부분 고쳤다. ○ AI 학습 전에 모아야 할 데이터양을 미리 계산하고, 같은 데이터라도 구성을 바꿔 학습 시간을 줄이는 데 활용할 수 있다. 또한 학습 정답률만으로 학습 상태를 판단하면 안 된다는 점을 보여 준다.		
주요어 (Key Words/ 5개 이내)	Grokking, 일반화, Transformer, 데이터 요구량, 연산 표		

최 종 보 고 서

1 탐구배경 및 동기

신경망이 학습 예제를 암기하는 과정과 규칙을 일반화하는 과정은 서로 다르다. 두 현상은 한 모델에서 공존할 수 있지만, 나타나는 시점에는 큰 차이가 있을 수 있다. 본 탐구는 각 현상이 언제, 어떤 조건에서 나타나는지를 정량적으로 규명하고자 한다.

□ 1.1 암기와 일반화는 어떻게 구분되는가

- 이웃한 두 수를 더하는 수열 규칙을 학습시키며 학습 예제 중 5~20%를 골라 각 예제에서 출력 위치 하나를 의도적으로 오답으로 바꾸었다. 모델은 학습에 사용하지 않은 평가 문제에서 조건 평균 99~100%(시행별 97~100%)의 정확도를 보였으므로 규칙을 학습한 것으로 볼 수 있다.
- 그러나 오답이 포함된 학습 문제에서는 암기한 오답을 거의 100% 그대로 출력하였고, 20만 step(가중치 갱신 횟수)까지 학습해도 변하지 않았다. 이때 모델의 예측 확률을 기준으로 원래 정답의 순위 중앙값은 50개 후보 중 2위였다(4.5절).
- 즉 한 모델 안에서 규칙의 학습과 개별 답의 암기가 공존한다. 이는 학습 정확도만으로 암기와 일반화를 구분할 수 없음을 뜻하며, 본 탐구의 출발점이 되었다.

□ 1.2 암기 이후에 나타나는 지연된 일반화(Grokking)

- 신경망은 학습 예제를 모두 맞힌 뒤에도 오랫동안 학습에 쓰이지 않은 문제를 맞히지 못하다가, 어느 시점에 갑자기 일반화하기도 한다. [1]에서는 이 현상을 Grokking이라 명명하였다.
- 본 탐구의 기본 과제에서도 같은 현상이 나타났다(그림 1). 학습 정확도는 약 300 step에 100%에 도달하였으나, 평가 정확도는 약 20,000 step까지 거의 0%에 머문 뒤 21,000~24,500 step 사이에 급격히 상승하여 24,500 step에 95%, 25,300 step에 100%에 도달하였다.

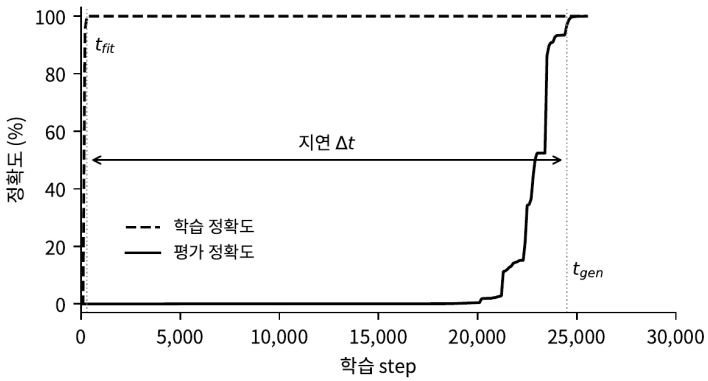


그림 1. 기본 과제의 학습 곡선(N = 768, 시드 0). 학습 정확도와 평가 정확도는 출력 5개 위치를 모두 맞힌 예제의 비율이며, 5회 이동 중앙값으로 나타내었다.

◦ 이러한 차이가 존재하면 학습 정확도만으로는 모델이 규칙을 학습하였는지 판단할 수 없다. 또한 일반화에 필요한 데이터 양을 미리 알 수 없으면 데이터 수집과 학습 시간을 계획하기 어렵다.

□ 1.3 탐구 목적과 연구문제

◦ 선행연구는 Grokking이 일어나려면 일정량 이상의 학습 데이터가 필요하다는 '임계 데이터 크기'를 보고하였다([2], [3]). 다만 선행연구에서는 임계 데이터 크기가 과제의 성질에 따라 어떻게 달라지는지, 임계값 이상에서 일반화 지연에 어떤 요인이 영향을 주는지 충분히 설명하지 않았다.

◦ 기존 연구는 주로 두 수의 연산 표(a ◦ b mod p)를 직접 학습하는 과제를 다루었다. 본 탐구는 수열 안의 여러 위치가 같은 연산 표를 공유하는 과제를 사용하여, 한 예제가 표의 여러 칸을 동시에 제공하는 상황에서 암기와 일반화를 측정하였다.

◦ 본 탐구의 목적은 소형 Transformer가 수열 변환 규칙을 학습할 때 일반화에 필요한 학습 예제 수와 암기 이후의 일반화 지연을 정량화하고, 이를 사전에 예측하는 관계식을 도출하는 것이다.

- 연구문제 0: 일반화한 모델은 왜 학습 과정에서 암기한 오답을 계속 출력하는가?
- 가설 0: Weight Decay를 적용한 모델에서는 학습이 진행됨에 따라 오답으로 학습시킨 예제에 대해서 규칙에 부합하는 답을 예측하는 비율이 증가할 것이다([4]).
- 연구문제 1: 모델이 규칙을 일반화하려면 학습 데이터가 몇 개 필요한가?
- 가설 1: 모델은 연산 표를 학습해야 하므로, 표의 각 칸을 일정 횟수 이상 관찰하면 일반화할 것이다. 초기 실험(4.3절, 그림 5(가))에서 일반화는 칸당 관찰 수(2.4절) 약 2.3회 부근에서 시작되었다. 일반화에 필요한 칸당 관찰 수가 표 크기와 무관하다면, 예제당 서로 다른 칸 수가 같은 배선에서 일반화 경계 N_0(3.3절)는 표의 칸 수 C에 비례할 것이다 ($N_0 \propto C$).
- 연구문제 2: 모델이 암기 후 일반화에 도달하는 시간은 무엇으로 정해지는가?
- 가설 2: 한 예제는 연산 표의 여러 칸을 제공하므로, 학습 예제 수가 같다면 표의 더 많은 칸을 관찰할수록(관찰 비율이 높을수록) 지연이 짧아질 것이다.

2 이론적 배경

□ 2.1 Transformer와 일반화

◦ Transformer는 입력의 각 위치에서 다른 위치의 정보를 얼마나 반영할지 어텐션(Attention) 메커니즘으로 계산하는 신경망 구조이다([5]).

◦ 본 탐구에서는 학습 집합(Training Set)에 대한 정확도를 암기 정도의 지표로, 학습에 사용하지 않은 평가 집합(Test Set)에 대한 정확도를 일반화의 지표로 사용하였으며, 두 집합은 입력의 숫자 조합 단위로 분리하였다(3.1절).

□ 2.2 Grokking과 Weight Decay

- [1]에서는 덧셈, 나눗셈 등 두 수의 모듈러 연산(mod 97) 표의 일부만으로 학습한 소형 Transformer가, 학습 정확도는 10^3 step 이전에 거의 100%가 되었으나 평가 정확도는 약 10^5 step부터 급격히 올라 10^6 step 부근에서 100%에 도달하는 사례를 보고하였다.
- 이 현상은 주로 Weight Decay와 관련하여 설명된다. Weight Decay는 매 갱신마다 가중치를 일정 비율로 줄이는 규제(Regularization)로, 같은 학습 손실을 더 작은 가중치로 달성하는 일반화 회로를 암기 회로보다 유리하게 만든다([2], [6], [7]). 학습 데이터가 많을수록 암기 회로의 효율이 떨어지므로 일반화 회로로의 전환이 빨라진다([2]). 본 탐구는 AdamW([8])를 사용하였다. AdamW는 손실의 기울기에 따른 갱신과 별도로 가중치를 줄인다(Decoupled Weight Decay).
- 다만 Weight Decay 없이 Grokking이 일어난 사례도 보고되었다([9], [10]). 본 탐구의 설정에서는 Weight Decay가 0이면 10만 step 동안 일반화되지 않았다(4.3절).
- [2], [3]에서는 일반화에 필요한 최소 학습 데이터 수(임계 데이터 크기)가 존재함을 보고하였다. 본 탐구의 일반화 경계 N_0는 이 개념에 대응하며, 일반화 비율 50%를 기준으로 조건별로 측정한 값이다(3.3절).

□ 2.3 수열 규칙의 대칭과 등변군

- 규칙의 대칭은 입력의 위치를 바꾸었을 때 출력이 같은 방식으로 바뀌는지로 나타낸다. 위치를 바꾸는 순열 σ에 대해 모든 입력 x에서 $f(\sigma x) = \sigma f(x)$가 성립하면 규칙 f는 σ에 대해 등변성을 갖는다고 하며, 이러한 순열의 집합을 등변군(Equivariance Group), 그 원소의 수(항등변환 포함)를 등변군의 크기라고 한다. 예를 들어 기본 규칙(이웃 덧셈)은 입력을 한 칸 순환 이동하면 출력도 한 칸 순환 이동한다. 이는 모델의 대칭이 아니라 모델이 학습할 정답 규칙의 대칭이다.
- 각 출력 위치가 참조하는 입력 위치의 구조를 이하 '배선'이라 하며, 등변군의 크기는 배선으로 정해진다. 다섯 위치가 하나의 순환을 이루며 서로를 참조하는 5-순환 배선은 순환을 따라 0~4칸 돌리는 변환 5개가 조건을 만족하여 크기가 5이다. 세 위치가 서로 순환하여 참조하고 나머지 두 위치가 서로 참조하는 3+2 순환 배선은 $3 \times 2 = 6$, 여러 위치가 같은 위치를 참조하는 배선은 1 또는 2이다.

□ 2.4 연산 표의 관점: 표의 칸 수와 칸당 관찰 수

- 이웃 덧셈 규칙에서 각 출력값은 자기 위치의 입력값 a와 참조 위치의 입력값 b에 대응하는 연산 표의 값 T(a, b)로 정해진다(그림 2). 따라서 모델의 일반화는 이 표의 값을 맞히는 것으로 볼 수 있다.
- 연산 표의 칸 수 C: 수의 범위가 1~n일 때, a+b는 교환법칙이 성립하므로 (a, b)와 (b, a)를 같은 칸으로 세어 $C = n(n+1)/2$($n = 50$에서 1,275칸), a+3b는 교환법칙이 성립하지 않아 두 순서를 구분하므로 $C = n^2$(2,500칸)이다. 입력의 수가 서로 다르므로 $a = b$인 칸은 학습과 평가에 나오지 않지만, 본 탐구는 이 칸을 포함한 전체 표의 칸 수를 C로 사용하였다.

○ 한 예제(수 m개)는 표의 칸을 최대 m개 제공한다. 본 탐구는 표의 관찰 상태를 두 가지 기준으로 나타낸다.

- 관찰 비율(Coverage): 연산 표의 전체 칸 중 학습 집합에 한 번 이상 나타난 칸의 비율.
- 칸당 관찰 수 = (학습 예제 수 N × 한 예제가 제공하는 서로 다른 칸 수) ÷ C. 표의 각 칸이 학습 집합에 평균 몇 번 나타나는지를 나타내며, 학습 중 갱신 횟수가 아니라 학습 데이터 안의 출현 횟수이다. 분모가 전체 칸 수 C이므로 N과 서로 다른 칸 수가 같으면 관찰 비율과 무관하게 값이 같다. 한 번 이상 나타난 칸만 분모로 삼은 값(이하 관찰된 칸당 관찰 수)은 칸당 관찰 수 ÷ 관찰 비율이며, 관찰 비율이 낮을수록 커진다.

□ 2.5 오답(라벨 노이즈)

○ [4]에서는 모듈러 연산 표의 일부 정답을 무작위 오답으로 바꾸어 학습시켰다. 모델은 다층 퍼셉트론(Multi-Layer Perceptron, MLP), 손실 함수는 평균 제곱 오차(Mean Squared Error, MSE)를 사용했다. 규제가 약하면 오답의 암기와 일반화가 공존하고, 규제가 적절히 강하면 암기한 오답을 잊고 규칙에 맞는 답을 출력하는 단계가 나타난다고 보고하였다. [4]의 주요 실험은 MLP와 MSE이며, 부록에서는 Transformer와 CE 손실도 다루었다. CE 손실에서도 같은 단계가 나타났으나, 오답을 잊는 단계는 더 강하고 좁은 범위의 규제에서만 나타났다.

○ 연구문제 0에서는 선행연구의 결과가 수열 과제와 Transformer에서도 재현되는지 검증하고, 오답의 유지와 교정에 영향을 미치는 조건을 비교한다(4.5절).

3 탐구 과정

□ 3.1 과제와 규칙

○ 입력은 1~n(기본 n = 50)에서 고른 서로 다른 정수 m개(기본 m = 5)로 된 수열이고, 출력은 같은 길이의 수열이다(그림 2).

○ 기본 규칙(이웃 덧셈): $y_i = T(x_i, x_{i+1})$, $T(a, b) = [(a + b) \bmod n] + 1$. 마지막 위치는 첫 위치를 참조한다.

○ 비교 규칙

- 배선: 각 출력 위치가 참조할 입력 위치를 바꾼 12종. 위치를 바꾸어도 같은 계산 관계가 유지되는 규칙은 여러 위치에서 계산 방식을 공유할 수 있으므로, 대칭이 일반화 지연과 관련될 가능성을 검토하기 위해 등변군 크기 1, 2, 5, 6마다 3종씩 골랐다(2.3절). 고른 배선은 등변군 크기와 한 예제가 제공하는 서로 다른 칸 수의 순서가 서로 달라(등변군 5는 5개, 6과 1은 4개, 2는 3~4개), 결과 분석에서 두 요인을 비교할 수 있었다.
- 참조 그래프: 수열의 위치 1~m을 점으로 두고, 각 출력 i마다 자기 위치 i와 참조 위치를 선으로 연결한 그림이다(그림 2(나)). 기본 규칙은 1–2–3–4–5–1의 선 5개가 하나의 고리를 이룬다.
- 선 하나는 한 예제에서 연산 표의 칸 하나에 대응한다. 다만 두 출력 i, j가 서로의 위치

를 참조하면(2-순환) 같은 선이 두 번 그어지고, a+b에서는 교환법칙 때문에 두 출력이 표의 같은 칸($T(x_i, x_j) = T(x_j, x_i)$)을 제공한다. 따라서 a+b에서는 서로 다른 선의 수가 한 예제가 제공하는 서로 다른 칸 수와 같다. a+3b에서는 두 출력이 서로 다른 칸을 제공하므로, 배선과 관계없이 한 예제가 서로 다른 칸 m개를 제공한다.

- 모든 점이 선을 따라 하나로 이어지면 '연결', 둘 이상으로 나뉘면 '비연결'이라 한다. 예를 들어 위치 1, 2, 3이 순환하며 참조하고 4, 5가 서로 참조하는 3+2 순환 배선(2.3절)은 {1, 2, 3}과 {4, 5}로 나뉘는 비연결이며, 4와 5 사이의 선이 두 번 그어지므로 a+b에서 서로 다른 칸은 4개이다.
- 연산: a+3b(교환법칙 없음), a×b(곱셈), 규칙 없는 무작위 표.
- 합성 규칙: 덧셈 두 번($y_i = [(x_i + 2x_{i+1} + x_{i+2}) \bmod n] + 1$), 정렬과 덧셈을 합성한 규칙.
- 수열 길이 m = 2~6, 수의 범위 n = 19~101.

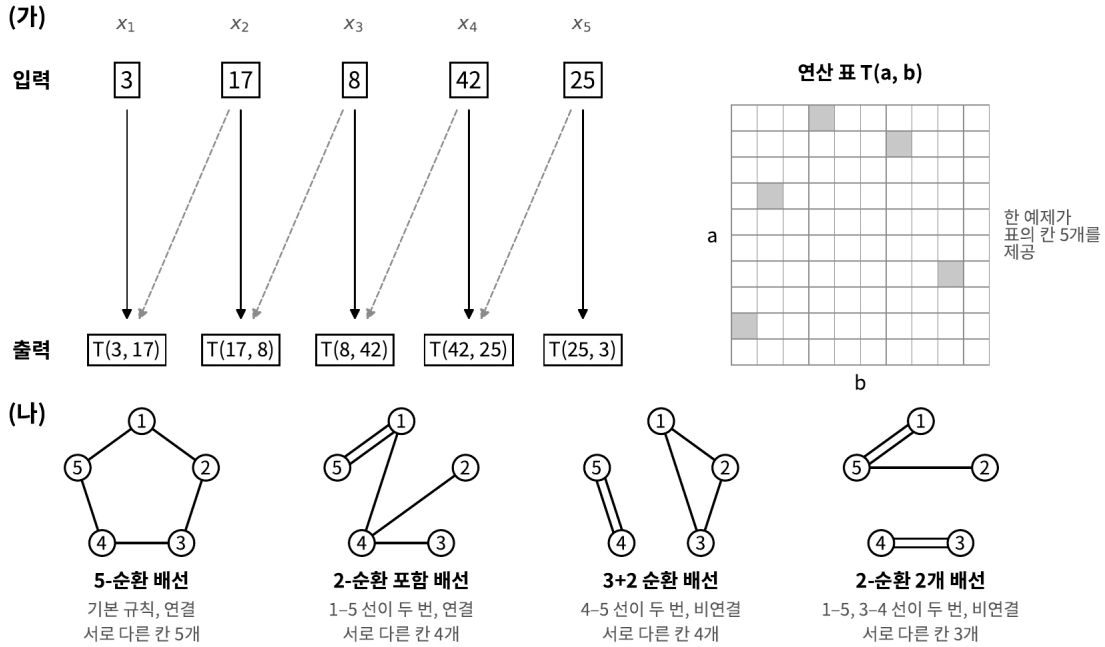


그림 2. (가) 과제의 구조. 각 출력값은 자기 위치와 참조 위치의 입력값으로 연산 표 T에서 찾은 값이며, 한 예제는 표의 칸을 최대 m개 제공한다. 실선 화살표는 자기 위치, 점선 화살표는 참조 위치를 나타낸다(마지막 출력의 참조 화살표는 생략). (나) 표 5의 네 가지 배선 구조를 나타낸 참조 그래프의 예(3.1절). 점은 수열의 위치이고, 겹선은 같은 선이 두 번 그어진 경우(2-순환)이다. 서로 다른 칸 수는 a+b 기준이다.

- 오답 조건(연구문제 0): 오답을 넣은 출력 위치의 수가 학습 예제 수 N의 5, 10, 20%가 되도록 하였다. 오답 방식은 학습 집합에 같은 계산의 정답 사례가 남는지에 따라 두 가지로 나누었으며, 두 방식의 오답 위치 수를 거의 같게 맞추었다.
  - 흩어진 오답: 학습 예제 중 해당 비율만큼을 골라, 고른 예제마다 출력의 한 위치를 정답이 아닌 무작위 값으로 바꾼다. 같은 연산 표 칸이 다른 예제에서는 정답으로 나오므로 대부분 정답 사례가 남는다(N = 768에서 오답 위치의 약 3~5%는 예외). 따라서 다른 예제의 동일 계산에 대한 정답 사례를 활용해 교정할 수 있다.
  - 같은 칸 오답: 연산 표의 칸을 골라, 학습 집합에서 해당 연산 표의 칸에 대응하는 모든

출력 위치를 같은 오답으로 바꾼다. 표의 일부 칸 값을 바꾼 것과 같으며, 오답 위치 수가 흩어진 오답의 위치 수 이상이 될 때까지 칸을 더한다(마지막 칸 때문에 최대 약 9% 많았다). 바꾼 칸은 학습 집합 어디에도 정답 사례가 남지 않으므로, 다른 칸에서 배운 규칙을 적용해야 교정할 수 있다.

○ 데이터 분할: 입력의 숫자 집합 단위로 학습 집합과 평가 집합(수열 과제는 대부분 20,000개, 두 수 오답 실험은 125개)을 나누어 같은 숫자 조합이 두 집합에 함께 들어가지 않도록 하였고, 학습 집합의 크기는 예제 수 N으로 정하였다. 같은 조건을 반복 학습할 때는 데이터 분할과 오답 위치, 값을 고정하고 시드로 모델의 초기값을 바꾸었다(미니배치 실험에서는 배치 순서도 달랐다). 예외는 예제를 골라 분할을 구성한 관찰 비율 실험(4.3절, 그림 6)과 다른 무작위 분할을 사용한 4.3절의 민감도 분석이다.

□ 3.2 모델과 학습

○ 기본 모델은 층(Layer) 2개, 은닉 차원(Hidden Dimension) 128, 어텐션 헤드(Attention Head) 4개로 된 Transformer이다. 입력 토큰 뒤에 출력 위치마다 그 위치의 값을 예측하기 위한 쿼리 토큰을 하나씩 두어 m개 위치를 한 번에 출력한다(병렬 출력).

○ 비교 모델은 확장 모델(4층, 은닉 차원 256, 어텐션 헤드 8개, 파라미터 약 8배)과 GPT형 디코더(이전 출력을 참조하여 다음 출력을 차례로 생성)이다.

○ 학습 설정은 표 1과 같다. 학습률 10^{-3}에서는 32비트 부동소수점(FP32) 연산이나 기울기 크기 제한(Gradient Clipping)을 적용해도 학습 도중 정확도가 급락하여 3×10^{-4}를 사용하였다.

<표 1> 학습 설정

항목	설정
기본 모델	2층 Transformer, 은닉 차원 128, 어텐션 헤드 4개, 병렬 출력
비교 모델	확장 모델(4층, 은닉 차원 256, 어텐션 헤드 8개), GPT형 디코더
손실 함수	출력 위치별 교차 엔트로피(Cross-Entropy, CE)의 평균. 두 수 과제의 비교 실험(4.5절)에서는 MSE(2.5절)도 사용: 출력 logit(확률로 변환하기 전의 출력값)과 정답 one-hot 벡터(정답 값의 성분만 1이고 나머지는 0인 벡터)의 차를 제곱하여 더한 값의 위치별 평균
옵티마이저	AdamW ($\beta_1 = 0.9$, $\beta_2 = 0.98$)
학습률	3×10^{-4} (처음 100 step 동안 학습률을 선형으로 높이는 워밍업 후 고정). 두 수 과제의 MSE 비교 실험 일부는 10^{-3}
Weight Decay	1.0 (규제 실험 0~15)
배치	전체 배치(Full Batch, 매 갱신에 학습 집합 전체 사용), 일부 합성 규칙 실험은 미니배치(배치 크기 2,048)
최대 학습 step 수	4만~20만 step (실험별, 무작위 표 실험은 3만 step)
판정 기준	암기: 학습 정확도 0.99, 일반화: 평가 정확도 0.95 (평가 표본은 최대 4,096개)
반복	조건마다 난수 시드를 변경하여 3~10회 학습(학습 과정 추적은 2회)

□ 3.3 측정

○ 정확도는 학습 집합과 평가 집합에서 각각 무작위로 고정한 4,096개(집합이 더 작으면 전

체)에 대해, 출력 m개 위치가 모두 맞은 예제의 비율로 정의하였다.

- 암기 시점 t_{fit}은 학습 정확도가 0.99에 처음 도달한 step, 일반화 시점 t_{gen}은 평가 정확도가 0.95에 처음 도달한 step이다. 지연은 $\Delta t = t_{gen} - t_{fit}$이며, 일반화 기준에 도달한 시행에 대해서만 계산하였다. 로그를 취할 때는 지연을 최소 50 step으로 두었다.
- 일반화 경계 N_0는 다음과 같이 정하였다. 한 조건(규칙, 수의 범위 n, 수열 길이 m, 모델과 학습 설정)에서 학습 예제 수 N을 몇 가지 값(이하 격자)으로 바꾸고, 각 N에서 시드를 바꾸어 여러 번 학습하여 정해진 최대 학습 step 수 안에 일반화한 비율을 구하였다. N이 커질수록 이 비율은 높아지며, 비율이 50%가 되는 학습 예제 수를 경계로 한다.
- 50%가 두 격자값 사이에 있으면, 그 구간에서 일반화 비율이 log N에 대해 직선으로 변한다고 보고 50% 지점을 구하였다(로그 척도 선형 보간). 예를 들어 n = 23, a+b에서 N = 190은 0/10, N = 220은 7/10이 일반화하였으므로 경계는 약 211이다(표 3).
- 관계식은 조건별 N_0에 $\log N_0 = \log a + b \cdot \log C$를 최소제곱으로 적합하여 구하였다. a는 계수, b는 지수로 4.1절 관계식의 2.82와 0.763에 해당하며, 연산 a+b의 a, b와는 다르다. 지수 b의 95% 신뢰구간은 부트스트랩으로 추정하였다. 4.1절의 9개 조건 관계식은 조건을 복원추출로 다시 뽑아 적합하는 과정을, 4.2절의 조건별 관계식은 각 학습 예제 수에서 학습 시행을 복원추출로 다시 뽑아 경계와 관계식을 다시 구하는 과정을 반복하였다.
- 오답 실험에서는 오답을 넣은 학습 출력 위치에서 그 오답을 출력하는 비율(오답 유지율)과 원래 정답을 출력하는 비율(교정률), 모델의 예측 확률에서 원래 정답이 차지하는 순위, 평가 문제에서 오답을 넣은 연산 표 칸에 대응하는 출력 위치 중 학습한 오답을 예측한 비율(전파율)을 1,000 step마다(수열 과제의 Weight Decay 비교 실험은 250 step마다, 학습 초반은 더 촘촘히) 기록하였다. 한 칸에 서로 다른 오답이 둘 이상이면 처음 배정된 오답 값을 기준으로 전파율을 계산하였다. 이때 평가 정확도는 오답을 넣은 칸이 하나도 나오지 않는 평가 문제로 계산하였다.
- 판정 기준의 영향을 보기 위해 암기 기준(0.95, 0.99)과 일반화 기준(0.90, 0.95, 0.99)의 6가지 조합으로 주요 결과를 재산출하였다(4.1절, 4.3절).
- 등변군은 무작위 입력 200개에서 $f(\sigma x) = \sigma f(x)$가 모두 성립하는 순열을 찾아 구하였다.

□ 3.4 실험 구성

- 표 2는 실험을 목적별로 정리한 것이다. 전체 학습 시행 수는 약 4,700회이다.

<표 2> 실험 구성

목적	바꾼 조건	학습 시행 수	결과
학습 설정 결정(예비)	학습 예제 수, 학습률, 연산 정밀도	약 260	3.2절
대칭 가설 검증	배선 12종(a+b)과 8종(a+3b), 첫 칸 참조 규칙 1종(본문 제외)	525	4.3절
지연과 관찰 수, 관찰 비율	칸당 관찰 수, 관찰 비율(예제 구성)	460	4.3절
경계와 표 크기	수의 범위 n = 23~101, 수열 길이 m = 2~6, 출력 위치 마스킹	760	4.1절
학습 설정의 영향	Weight Decay 0~15, 모델 크기	675	4.2절, 4.3절
모델 구조	GPT형 디코더, 확장 모델	719	4.2절
연산	곱셈 a×b (n = 31~71)	234	4.2절
합성 규칙	덧셈 두 번, 정렬과 덧셈	450	4.2절
학습 과정 추적	200 step 간격 저장(16회), 로그 간격 저장(16회), 무작위 표(18회)	50	4.4절
오답	오답 방식, 비율, 과제 형태, 손실 함수, Weight Decay	555	4.5절
합계		**약 4,700**	

4 탐구 결과

□ 4.1 연구문제 1: 연산 표 크기에 따른 일반화 경계의 거듭제곱 관계

○ 수의 범위(n = 23~101)와 연산(a+b, a+3b)을 바꾼 9개 조건의 경계는 칸 수 C에 대한 거듭제곱 관계를 따랐다(표 3, 그림 3). 9개 조건 모두 아래 식의 약 ±10% 안(최대 −10.1%)에 놓였다.

$$N_0 \approx 2.82 \times C^{0.763}$$

<표 3> 연산 표 크기별 일반화 경계의 실측값과 관계식 값

연산	n	칸 수 C	실측 경계	관계식 값	실측/관계식
a+b	23	276	211	206	1.03
a+b	31	496	329	322	1.02
a+b	50	1,275	623	661	0.94
a+b	61	1,891	880	893	0.98
a+b	71	2,556	1,180	1,124	1.05
a+b	101	5,151	2,063	1,919	1.08
a+3b	31	961	533	533	1.00
a+3b	41	1,681	827	816	1.01
a+3b	50	2,500	993	1,105	0.90

주: 실측 경계는 로그 척도 선형 보간값이고, 관계식 값과 비율은 반올림하지 않은 적합 계수로 계산하였다.

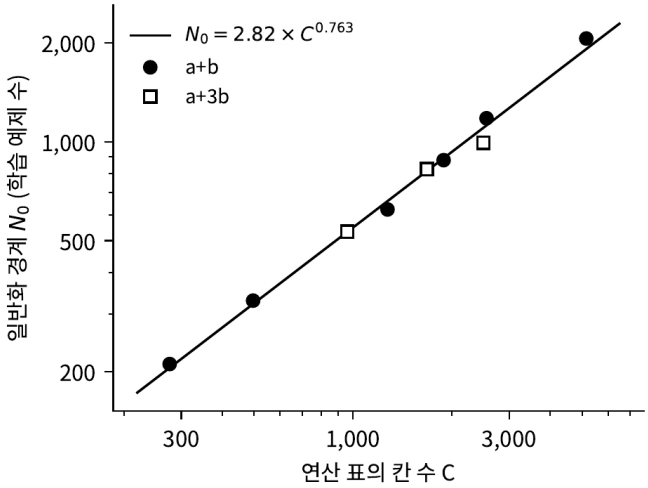


그림 3. 연산 표의 칸 수 C와 일반화 경계 N_0의 관계. 두 축은 로그 척도이며, 직선은 관계식 $N_0 = 2.82 \times C^{0.763}$이다.

- 관계식 도출 후 5개 표 크기를 새 격자로 다시 측정하였을 때(이 중 a+b의 n = 41은 새 표 크기)도 실측 경계는 관계식 값의 0.89~1.13배였다. 일반화 기준을 0.90, 0.95, 0.99로 바꾸어도 경계는 변하지 않았는데(기본 모델 a+b, n = 31~71), 대부분의 학습에서 평가 정확도가 0에서 1로 짧은 구간에 상승하였기 때문이다.
- 가설 1을 검증하기 위해 n = 23, 101의 경계를 실험 전에 예측하였다. 일반화에 필요한 칸당 관찰 수가 표 크기와 무관하게 약 2.3회라면 경계는 n = 23에서 약 130, n = 101에서 약 2,370이어야 하나, 실측 경계는 약 211, 2,063이었다. 작은 표는 예측보다 많은 예제가, 큰 표는 적은 예제가 필요하였고, n = 23은 관찰 수 3.4회(N = 190)에서도 0/10이었다. 관계식의 지수 역시 95% 신뢰구간(0.71~0.83)이 1을 포함하지 않아 $N_0 \propto C$와 맞지 않았다. 관계식에 따르면 경계의 칸당 관찰 수는 $C^{-0.237}$에 비례하여, 서로 다른 칸 5개 배선에서 n = 23은 약 3.7회, n = 50은 약 2.6회이다.
- 같은 연산 표에서는 경계가 칸당 관찰 수가 아니라 학습 예제 수로 정해졌다. n = 50, a+b에서 수열 길이 m을 2~6으로 바꾸면 경계에서의 칸당 관찰 수는 m = 2의 약 0.6회부터 m = 6의 약 3.3회까지 달라졌으나, 경계는 모두 약 520~720개였다(m = 3은 425~638개 사이). 관계식을 학습 예제 수 N으로 나타낸 것은 이 때문이며, 가설 1의 약 2.3회는 m = 5에서의 값이다.
- 단, 관계식의 '예제'는 각 출력 위치가 연산 표의 서로 다른 칸에 대응하는 예제로 한정된다. 출력 m개 위치 중 일부만 손실 계산에 넣어 같은 관찰 수를 더 많은 예제로 구성한 조건(출력 위치 마스킹, Output Masking)은 예제 수를 2.5배로 늘려도 일반화가 빨라지지 않았고, 한 예제 안에서 같은 칸이 두 번 나오는 배선(2-순환)은 관계식보다 많은 예제가 필요하였다.

□ 4.2 다른 조건에서의 관계식: 모델, 연산, 규제, 합성 규칙

- 4.1절의 관계식 $N_0 \approx 2.82 \times C^{0.763}$은 기본 모델, Weight Decay 1, 연산 a+b와 a+3b에서 얻은 것이다. 조건을 바꾸어도 경계가 C의 거듭제곱을 따르는지, 따른다면 지수(표가 커질 때 경계가 늘어나는 빠르기)와 계수(경계의 전체 수준) 중 무엇이 달라지는지 확인하

였다(표 4, 그림 4). 비교를 위해 기본 모델도 같은 격자에서 다시 측정하였으며, 이때 지수는 0.72(95% 신뢰구간 0.62~0.81)로 4.1절의 0.763과 구분되지 않았다.

<표 4> 조건별 관계식의 지수와 경계 비율

조건	지수	경계 비율	비교 기준
기본 모델	0.72	1	—
확장 모델(파라미터 약 8배)	0.75	0.88~0.97배	기본 모델
GPT형 디코더	0.73	2.7~3.1배	기본 관계식
곱셈 a×b (n 소수)	0.85	0.66~0.87배	기본 관계식
곱셈 a×b (n = 50, 합성수)	—	약 0.5배	기본 관계식
Weight Decay 0.3~7	—	0.93~1.20배	Weight Decay 1
Weight Decay 10	—	1.39~1.74배	Weight Decay 1
Weight Decay 15	—	2.17~2.78배†	Weight Decay 1

주: 경계 비율은 비교 기준에 대한 실측 경계의 비율로, 계수의 변화를 나타낸다. 기본 관계식은 4.1절의 관계식이다. 모델과 연산은 n = 31, 41, 50, 61, 71(곱셈은 n = 47, 53 추가), 규제는 n = 31, 50, 71에서 측정하였다. 합성수 n = 50의 곱셈은 표 크기가 하나뿐이어서 지수를 구하지 않았고, 규제 실험은 수의 범위가 3개뿐이어서 지수를 비교하지 않았다. 규제의 비교 기준은 같은 격자에서 측정한 Weight Decay 1이다. Weight Decay 0.3의 n = 71 경계는 최대 학습 step 수 안에 일반화하지 못한 학습이 있어 상한값이다. † step 200~500에 일반화한 뒤 step 1,000~2,000 사이에 학습 정확도와 평가 정확도가 함께 0으로 떨어졌다.

- 모델 파라미터를 약 8배로 늘려도 경계는 기본 모델의 0.88~0.97배였고, 지수의 95% 신뢰구간(0.71~0.80)도 기본 모델과 겹쳤다. 큰 모델일수록 임계 데이터 크기가 커진다는 [3]과 방향이 다르나, 본 탐구는 두 가지 모델 크기만 비교하였다.
- GPT형 디코더의 경계는 다섯 가지 수의 범위 모두에서 기본 관계식의 2.7~3.1배였고, 이 비율에는 표 크기에 따른 추세가 없었다. 적합 결과는 $N_0 = 10.2 \times C^{0.732}$였다.
- 곱셈의 경계는 n이 소수인 여섯 가지 수의 범위에서 덧셈 관계식의 0.66~0.87배였다. 반면 합성수 n = 50의 곱셈은 C가 더 작은 n = 47(경계 400)보다도 적은 예제(약 325, 290~365 사이)로 일반화하여, 같은 칸 수라도 표의 구조에 따라 계수가 달라졌다. n = 50 곱셈 표는 나머지가 0인 칸(출력 값 1)이 7.8%로 소수 표(약 4%)의 약 2배였고, 결과값의 분포도 덜 고르게 퍼져 있었다(엔트로피가 최대값보다 n = 50은 0.29비트, n = 47, 53은 약 0.01비트 낮음).
- 경계는 Weight Decay 0.3~7에서 Weight Decay 1의 0.93~1.20배로 거의 변하지 않았으나 10에서 1.39~1.74배로 커져, 규제 세기에 따라 서서히 늘기보다 7과 10 사이에서 급격히 상승하였다(그림 4(나)). Weight Decay 15에서는 일반화 직후 학습이 붕괴하여 일반화가 유지되지 않았다(표 4 주, 4.5절).

○ 합성 규칙으로의 확장

- 덧셈 두 번($y_i = x_i + 2x_{i+1} + x_{i+2}$)은 출력이 세 값의 함수이므로 $C = n \times n(n+1)/2$이다. 경계는 n = 19(C = 3,610)에서 2,400~3,600 사이(기하평균 약 2,940), n = 23(C = 6,348)에서 4,000~6,000 사이(약 4,900)로, 기본 관계식 값(1,463, 2,251)의 2.0배, 2.2배였다. 두 경계의 비율 1.67은 관계식이 주는 비율 1.54와 비슷하였다.

- 덧셈 한 번의 표가 충분히 관찰되는 조건(n = 31, N = 4,096; n = 50, N = 16,384)에서도 덧셈 두 번은 일반화하지 않았다.
- 정렬과 덧셈을 합성한 규칙의 경계는 구성 규칙 중 일반화에 더 많은 예제가 필요한 규칙보다 컸다. 첫 값 더하기 → 정렬은 일반화 기준 0.85, 0.90에서 1,319, 1,774(첫 값 더하기 855의 1.5배, 2.1배)였고, 0.95 기준에서는 N = 2,048에서도 2/5라 경계를 구하지 못하였다. 정렬 → 이웃 덧셈은 0.95 기준에서 1,611로 정렬(887)의 약 1.8배였다. 정렬이 포함된 규칙은 평가 정확도가 0.94~0.96 부근에 머무는 경우가 있어 일반화 기준 0.85, 0.90, 0.95를 함께 적용하였다.
- 경계 부근에서 검사한 조건(n = 19, 23)에서 전체 배치와 미니배치(배치 크기 2,048) 모두 3/3 일반화하였다.

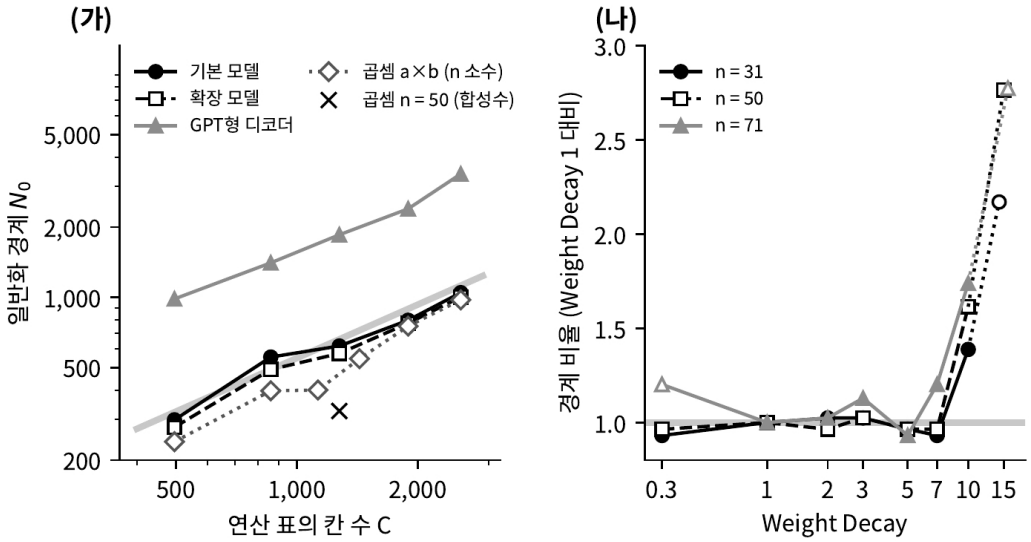


그림 4. 조건별 일반화 경계. (가) 모델과 연산에 따른 연산 표의 칸 수 C와 일반화 경계 N_0의 관계(두 축은 로그 척도, 굵은 회색 선은 기본 관계식(그림 3의 직선)), (나) Weight Decay 1 대비 경계 비율(가로축 로그 척도, 회색 선은 비율 1). (나)의 빈 기호는 최대 학습 step 수 안에 일반화하지 못한 학습이 있어 상한값만 얻은 경계(Weight Decay 0.3, n = 71)와, 일반화가 유지되지 않은 Weight Decay 15의 경계이다.

□ 4.3 연구문제 2: 반복 관찰에 따른 일반화 지연의 감소와 사전 예측

○ 먼저 연구 초기에 세운 대칭 가설을 검토하였다. a+b 배선 12종에서 배선별 지연 중앙값의 log와 등변군 크기의 상관계수는 −0.1~−0.3에 그친 반면, 예제당 서로 다른 칸 수와의 상관계수는 −0.91~−0.93이었다(모든 배선이 일반화한 N = 1,024~1,280; 표 5). 등변군은 그대로 두고 배선 8종의 연산을 a+3b로 바꾸어 모든 배선이 서로 다른 칸 5개를 제공하도록 하자, N = 1,280에서 배선 간 지연 차이가 a+b의 약 22배(100~2,200 step)에서 약 1.7배(4,600~7,800 step)로 줄었고, 연결, 비연결 간 차이도 거의 없었다(5,850, 5,800 step). 따라서 지연을 정하는 것은 대칭이 아니라 예제당 서로 다른 칸 수였다.

<표 5> 배선 구조별 일반화 비율과 지연 중앙값(step)

서로 다른 칸 수	배선 구조	등변군 크기	N = 768	896	1,024	1,152	1,280
5	5-순환(연결)	5	15/15 (4,900)	15/15 (2,500)	15/15 (400)	15/15 (200)	15/15 (100)
4	2-순환 포함(연결)	1, 2	13/20 (24,500)	19/20 (6,400)	20/20 (2,400)	20/20 (1,050)	20/20 (250)
4	3+2 순환(비연결)	6	1/15 (10,700)	12/15 (9,300)	15/15 (4,400)	15/15 (2,300)	15/15 (700)
3	2-순환 2개(비연결)	2	0/10	3/10 (13,300)	10/10 (7,600)	10/10 (3,900)	10/10 (2,100)

주: 일반화 비율은 일반화한 학습 시행 수/전체 학습 시행 수이고, 괄호 안은 지연 중앙값(step)이다. 각 행은 같은 구조의 배선을 묶은 것으로, 학습 시행 수는 배선 수 × 5회이다. 출력 위치 1~5가 참조하는 입력 위치를 차례로 적으면 5-순환은 (2,3,4,5,1), (2,5,4,1,3), (2,4,1,5,3), 2-순환 포함은 (5,4,4,1,1), (2,5,1,5,4), (5,1,1,2,1), (2,4,4,2,1), 3+2 순환은 (4,5,2,1,3), (3,5,4,1,2), (4,3,2,5,1), 2-순환 2개는 (4,4,5,1,3), (5,5,4,3,1)이다. 배선의 모양은 그림 2(나)에, '연결', '비연결'은 3.1절에, 등변군 크기는 2.3절에 나타내었다.

○ 다만 서로 다른 칸 수만으로는 연산 간 차이를 설명할 수 없었다. a+3b는 모든 배선이 서로 다른 칸 5개를 제공하는데도 a+b의 5-순환 배선보다 지연이 수십 배 길었다(N = 1,280에서 각각 4,600~7,800 step, 100 step). a+3b의 표는 2,500칸으로 a+b(1,275칸)의 약 2배여서, 같은 학습 예제 수로는 각 칸을 약 절반만 관찰하기 때문이다. 이를 반영하여 칸당 관찰 수(2.4절)로 나타내자 a+b와 a+3b의 모든 배선이 하나의 곡선 부근에 모였고, 칸당 관찰 수가 약 0.4회 늘 때마다 지연은 약 절반으로 줄었다(조건 단위 log 지연과의 상관계수 −0.95, 그림 5(나)). 같은 조건에서 일반화 비율이 50%가 되는 칸당 관찰 수는 약 2.0~2.6회였다(a+3b 약 2.0회, a+b 약 2.2~2.6회, 그림 5(가)). 칸당 관찰 수와 지연의 관계는 판정 기준의 6가지 조합(3.3절)에서도 같았다(78개 조건, 조건 단위 상관계수 −0.92~−0.95, 지연이 절반이 되는 증가량 0.36~0.46회).

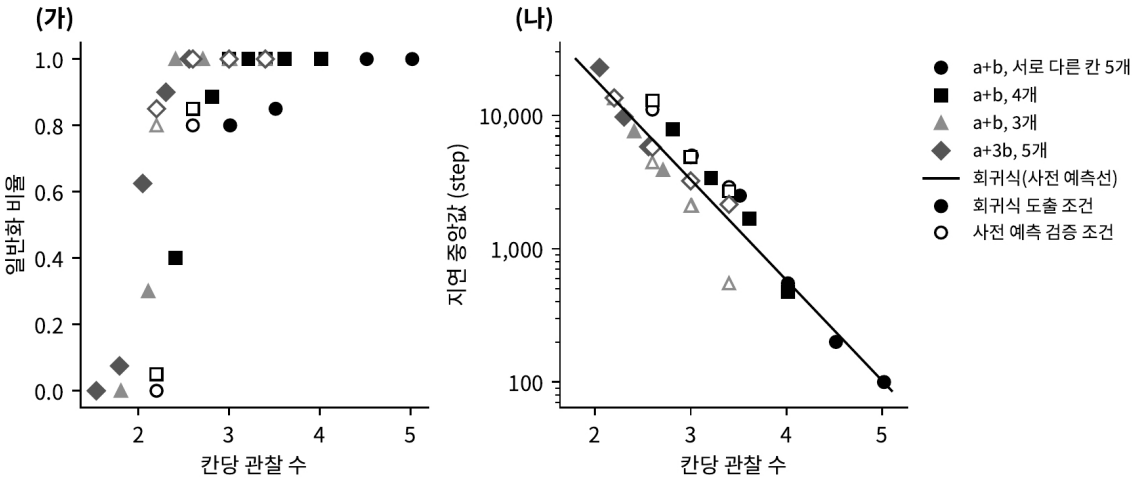


그림 5. 칸당 관찰 수에 따른 일반화 비율과 지연. (가) 일반화 비율, (나) 지연 중앙값(일반화 비율 50% 이상인 조건, 세로축 로그 척도). 채운 기호는 회귀식을 도출한 조건, 빈 기호는 사전 예측을 검증한 조건이며, 직선은 회귀식이다.

○ 이 결과로 얻은 회귀식 $\log_{10}\Delta t = 5.78 - 0.754 \times$ (칸당 관찰 수)로 6개 규칙 × 4개 관찰

수 수준(2.2~3.4), 즉 새 조건 24개의 지연을 실험 전에 예측하였다. 90% 이상 일반화한 17개 조건에서 실측/예측의 기하평균은 1.11배, 상용로그 표준편차는 0.21(약 1.6배)이었다(조건별 0.33~2.38배). 관찰 수 2.2에서는 학습 예제 수가 경계에 못 미친 조건(N = 561, 701)이 일반화하지 못하여 지연 예측을 적용할 수 없었다(4.1절).

○ 긴 지연은 경계 바로 위에서만 나타났다. 경계보다 충분히 많은 예제에서는 암기와 동시에 일반화하였고(예: 기본 규칙은 N = 2,048에서 지연 0 step), 경계 바로 위에서는 결과가 데이터 분할에도 민감하여 새 분할 2개(각 5회)를 합치면 일반화 비율이 8/10에서 6/10으로 낮아지고 지연이 약 1.65배로 늘었다. 그 밖의 조건에서 분할에 따른 지연 차이는 모두 1.5배 이내(0.85~1.14배)였다.

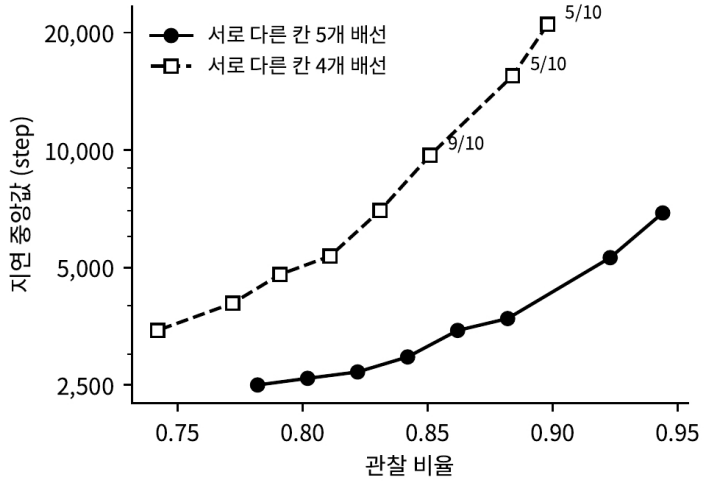


그림 6. 관찰 비율에 따른 지연 중앙값(학습 예제 768개 고정). 세로축은 로그 척도이다. 점 옆의 숫자는 일반화 비율(일반화한 학습 시행 수/전체 학습 시행 수)이며, 숫자가 없는 점은 10/10이다. 서로 다른 칸 5개 배선은 기본 규칙(5-순환(연결)), 4개 배선은 2-순환 포함(연결) 배선 (2,5,1,5,4)이다.

○ 관찰 비율도 log 지연과의 상관계수가 −0.86으로 컸지만, 학습 예제 수나 예제당 서로 다른 칸 수가 늘면 칸당 관찰 수와 관찰 비율이 함께 커지므로 상관만으로는 어느 쪽이 지연을 정하는지 단정할 수 없다. 가설 2를 직접 검증하기 위해 학습 예제 수(768개)와 예제당 서로 다른 칸 수를 고정하고, 연산 표의 같은 칸이 여러 예제에 반복되는 정도만 조절하였다. 이때 칸당 관찰 수는 그대로이고, 관찰 비율이 낮을수록 관찰된 칸당 관찰 수(2.4절)가 커진다. 그 결과 관찰 비율이 낮을수록, 즉 같은 칸을 여러 예제에서 반복 관찰할수록 지연이 짧아져(그림 6) 가설 2의 예측과 반대였다. 이 실험에서 칸당 관찰 수는 고정되어 지연 차이를 설명하지 못하지만, 관찰된 칸당 관찰 수는 두 배선에서 지연과의 상관계수가 각각 −0.95, −0.96이었고, 지연이 절반이 되는 증가량(0.29~0.46회)도 앞의 약 0.4회와 비슷하였다. 따라서 지연은 학습 집합에 나온 칸을 평균 몇 번 반복 관찰하였는지로 설명할 수 있다.

○ 지연의 크기는 규제 세기에 따라 크게 달라졌다. Weight Decay가 0이면 10만 step 동안 일반화한 학습이 없었고(0/20), 0.1의 지연은 1의 약 6~15배, 3은 1/3~1/4이었다. 다만 일반화가 관찰된 모든 Weight Decay(0.1~3)에서 칸당 관찰 수가 많은 조건의 지연이 더 짧아, 칸당 관찰 수에 따른 순서는 유지되었다. Weight Decay 0.3~7에서 경계가 거의 변하지 않았던 것(4.2절)과 함께 보면, 규제는 경계보다 지연에 영향을 주었다. 이는 임계

데이터 크기가 규제 세기와 무관하고 일반화까지 걸리는 시간은 규제 세기에 따라 달라질 수 있다는 [2]의 예측과 맞는다.

□ 4.4 관찰 칸에서 미관찰 칸 순서로 나타나는 정확도 상승

○ 4.3절의 지연이 학습의 어느 단계에서 생기는지 보기 위해, 경계 부근의 16회 학습(5-순환과 3+2 순환 배선, 연산 a+b와 a+3b, N = 1,024와 1,280, 각 2회)에서 모델을 200 step 간격으로 저장하였다. 평가 문제의 각 출력 위치를 대응하는 연산 표 칸이 학습 집합에 나온 경우(관찰 칸)와 나오지 않은 경우(미관찰 칸)로 나누어 정확도를 따로 추적하였다(그림 7). 학습 시행 수가 적어 탐색적 결과로 보고한다.

- 일반화한 14회의 학습 모두에서 관찰 칸의 정확도가 0.5에 도달한 시점이 미관찰 칸보다 200~2,000 step 빨랐다.
- 지연이 긴 7회(a+3b 6회, 3+2 순환 N = 1,024 1회)에서는 암기 시점의 관찰 칸 정확도가 0.06~0.15였고, 암기 이후 관찰 칸 정확도가 0.5에 도달하기까지 전체 지연의 68~86%가 걸렸으며, 관찰 칸과 미관찰 칸이 각각 0.5에 도달한 시점의 차이는 지연의 10~27%였다. 지연이 짧은 나머지 7회(지연 200~2,200 step)에서는 단계별 시간 비율이 조건에 따라 크게 달랐다.
- 규칙이 없는 무작위 표(칸 수 2,500으로 a+3b와 같음, N = 1,100~2,000, 9회 학습)는 200~500 step에 관찰 칸 정확도가 0.5에 도달하였고, 미관찰 칸은 무작위 추측 수준(1/50)에 머물렀다. 같은 조건의 a+3b가 관찰 칸 정확도 0.5에 도달하기까지 500~12,000 step이 걸린 것과 대조적으로, 칸 단위 학습 자체는 빨랐다.

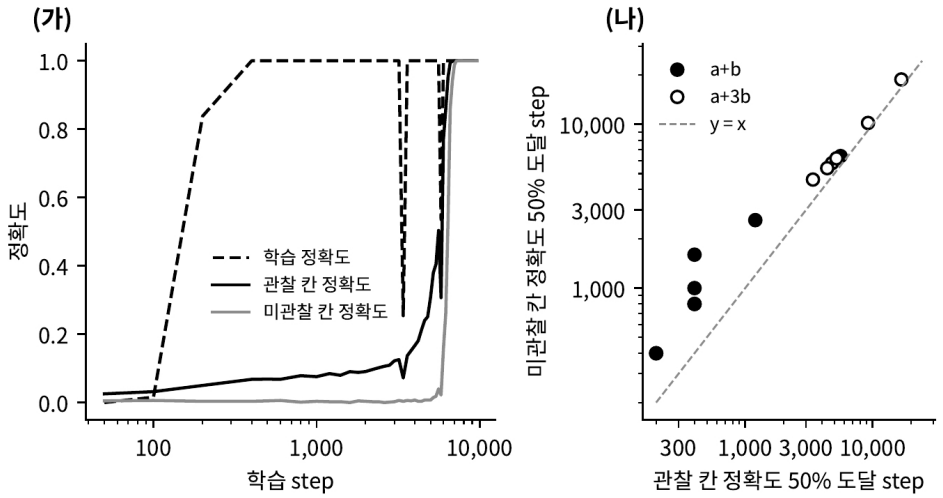


그림 7. 학습 중 관찰 칸과 미관찰 칸의 정확도 변화. (가) 한 차례 학습(a+b, 3+2 순환 배선, N = 1,024)의 정확도 곡선, (나) 일반화한 14회 학습에서 관찰 칸과 미관찰 칸의 정확도가 각각 0.5에 도달한 시점(step). 점선(y = x)보다 위의 점은 관찰 칸이 먼저 도달한 학습이다. 모델은 200 step 간격으로 저장하였다.

□ 4.5 연구문제 0: 규제 세기와 오답 구조에 따른 오답의 유지, 교정, 전파

○ 기본 과제(n = 50, m = 5)에 오답을 넣어 20만 step 동안 학습하였다. 조건은 N = 768, 2,048, Weight Decay 1, 2, 오답 방식 2가지(흩어진 오답, 같은 칸 오답), 오답 비율 5, 10, 20%를 조합한 24개이고, 조건마다 5회 학습하였다(그림 8).

- 20만 step 시점 오답 유지율은 120회 중 119회에서 1.00, 나머지 1회에서 0.95였다. 같은 기간 오답을 넣은 칸이 나오지 않는 평가 문제의 정확도는 0.97~1.00이었다.
- 오답을 넣은 위치에서 원래 정답의 예측 순위 중앙값은 대부분의 조건에서 50개 중 2위였고, 2위인 비율은 조건 평균 36~84%였다. 다만 원래 정답에 부여한 확률은 조건 평균 0.02 이하였다.
- N = 2,048의 흩어진 오답 조건은 step 200에 일반화하면서 오답을 넣은 위치에서도 원래 정답을 출력하였으나, 30회 중 26회는 step 500까지, 나머지도 step 2,000까지 오답을 모두 암기하였다. N = 768에서는 오답까지 먼저 암기한 뒤 일반화하였다.
- 흩어진 오답은 평가 문제로 거의 전파되지 않았다(전파율 조건 평균 최대 0.08). 같은 칸 오답은 N = 2,048에서 0.88~0.99로 전파되었고, N = 768에서는 정점(0.60~0.81) 이후 20만 step에 0.23~0.44로 줄었다(그림 8).
- N = 768에서 흩어진 오답의 비율이 클수록 일반화가 늦었다(Weight Decay 1, 오답 5%에서 6,000 step, 20%에서 10,000 step). 같은 칸 오답은 일반화 시점을 늦추지 않았다(5,000 step).

○ 이 범위의 규제(Weight Decay 1, 2)에서는 20만 step 안에 오답이 교정되지 않아 가설 0과 맞지 않았다.

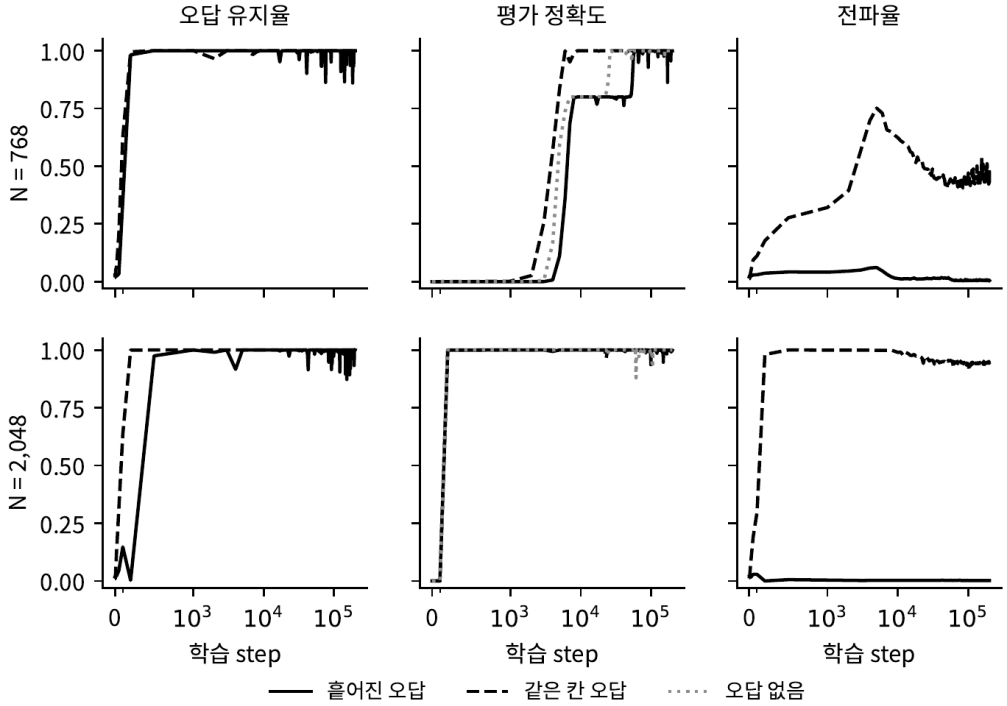


그림 8. 오답 실험의 학습 곡선(Weight Decay 1, 오답 비율 10%, 시드 5개 평균). 위는 N = 768, 아래는 N = 2,048이다. 평가 정확도는 오답을 넣은 칸이 나오지 않는 평가 문제로 계산하였다. 본문의 일반화 시점은 시행별 도달 시점의 중앙값이다.

○ 선행연구([4])와 결과가 다른 원인을 찾기 위해, 선행연구처럼 입력이 곧 표 한 칸인 두 수 과제(m = 2, n = 50, 학습 예제 1,100개, 오답 예제 10%)에서 손실 함수(CE, MSE, 표 1)와 Weight Decay(1~15)를 바꾸어 오답 유지율을 비교하였다(그림 9).

- Weight Decay 1~3에서는 두 수 과제에서도 20만 step 학습 끝의 오답 유지율이 1.00이었다. 오답 예제가 20%이면 일반화하지 못하였다(Weight Decay 1, 2, 3 각 0/5).
- 두 손실 모두 Weight Decay 3에서는 오답을 유지하고(1.00) 10에서는 교정하였다(오답 유지율 CE 0.005, MSE 0.03, 교정률 0.95, 0.82). 다만 MSE는 Weight Decay 1에서 일반화하지 못하였고, 일반화한 시행 수도 적었다(Weight Decay 3에서 1/4, 10에서 3/4). CE 손실은 step 200에 오답을 모두 암기한 뒤 일반화 시점(step 500~1,000)에 교정하였다.
- 두 수 과제에서는 규제 세기를 높이면 오답이 교정되었다. 오답 유지율은 Weight Decay 5까지 1.00이었다가 7에서 0.21로 급감하였고(5회 중 4회는 step 3,000~6,000에 0.1 아래로 내려갔고, 1회는 끝까지 약 0.99), 교정은 대부분 일반화 시점 전후에 일어났다(그림 9(가)).
- Weight Decay 3~5에서는 오답을 유지한 채 평가 정확도가 학습 후반에 낮아져 학습 끝에 평균 0.37~0.82였으나, 오답이 없는 대조 학습은 모두 1.00이었다(그림 9(나)). Weight Decay 15에서는 step 100~200에 오답을 일부 암기했다가 step 500까지 거의 모두 잊었으나(학습 끝 평균 0.04), 평가 정확도도 0.28에 그쳤다.

○ 수열 과제에서도 같은지 보기 위해 N = 1,024, 2,048, 4,096과 Weight Decay 1, 3, 5, 7, 10, 15를 함께 바꾸어, 오답 10%로 6만 step 동안 조건마다 4회 학습하였다(그림 9(가)에는 N = 2,048을 표시).

- 흩어진 오답은 학습 예제가 많을수록 약한 규제에서 사라졌다. 학습 끝 오답 유지율이 0.1 아래로 내려간 가장 약한 Weight Decay는 N = 1,024에서 7(0.00), N = 2,048에서 5(평균 0.08)였다. N = 4,096에서는 Weight Decay 3에서 오답 유지율이 크게 오르내렸으나 교정이 유지되지 않았고(학습 끝 평균 0.83), 5 이상에서는 처음부터 거의 암기되지 않았다(시행별 최대 0.07 이하).
- 같은 칸 오답은 더 강한 규제가 필요하였다. Weight Decay 5에서는 유지되었고(0.94~1.00), 7에서는 N이 커질수록 유지율이 0.27, 0.15, 0.00으로 감소하였으며, 10에서는 모든 N에서 조건 평균 0.05 미만이었다. 이때도 오답은 먼저 암기되었다가(최대 0.61~0.97) 줄어들었다.
- Weight Decay 1~7에서는 학습 끝 평가 정확도가 0.94~1.00이었다. Weight Decay 10에서는 N = 1,024의 흩어진 오답 조건 4회 중 1회가 일반화하지 못하였고 1회는 일반화한 뒤 평가 정확도가 0.88로 떨어졌으며, N = 4,096의 같은 칸 오답 조건에서도 1회가 일반화한 뒤 0.89로 떨어졌다. 또한 별도의 10만 step 실험에서 N = 768은 오답이 없어도 일반화하지 못하였다(0/4). Weight Decay 15에서는 모든 N에서 오답 유무와 관계없이 일반화에 실패하거나 학습이 붕괴하여 최종 평가 정확도가 0에 가까웠다.

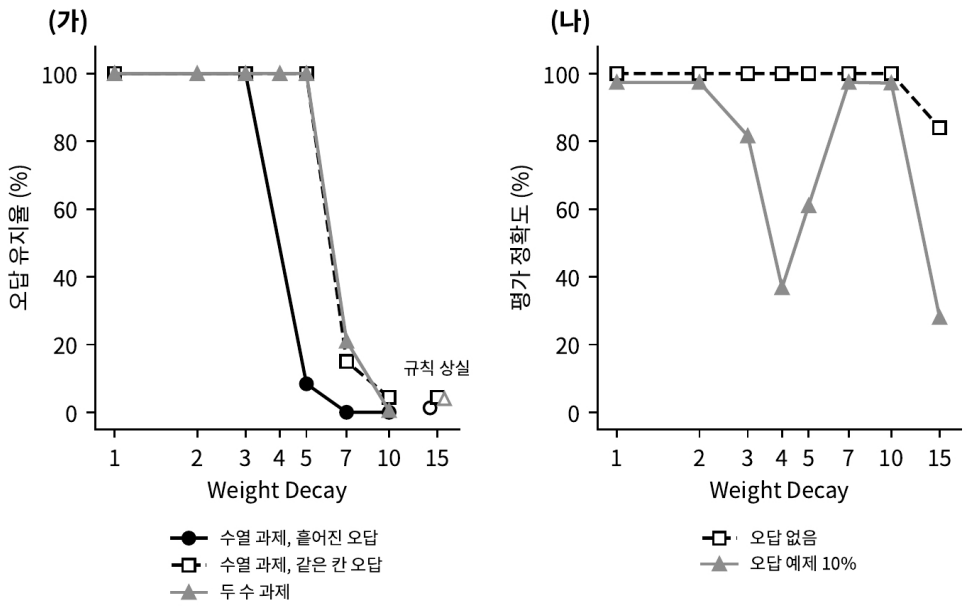


그림 9. Weight Decay에 따른 (가) 오답 유지율과 (나) 두 수 과제의 평가 정확도. 수열 과제는 학습 예제 2,048개, 오답 10%, 두 수 과제는 학습 예제 1,100개, 오답 예제 10% 조건이다. 수열 과제는 6만 step, 두 수 과제는 20만 step 시점의 값이다. (가)의 빈 기호(Weight Decay 15)는 규칙을 학습하지 못한 경우로, 선으로 연결하지 않았다.

5 결론 및 제언

□ 5.1 결론

○ 연구문제 1(가설 1 기각): 일반화에 필요한 학습 예제 수(경계)는 연산 표의 칸 수 C에 대해 $N_0 \approx 2.8 \times C^{0.76}$을 따랐다. 지수가 1보다 작아 경계가 칸 수에 비례하지 않았고($N_0 \propto C$와 불일치), 작은 표일수록 칸당 더 많은 관찰이 필요하였다. 이 관계식은 도출 후 다시 측정한 조건에서도 성립하였다. 모델 구조를 바꾸어도 지수의 차이는 구분되지 않았고 계수가 달라졌으며, 곱셈도 칸 수에 대한 거듭제곱 관계를 따랐고(지수 0.85), 합성 규칙(덧셈 두 번)은 기본 관계식보다 약 2배 많은 예제가 필요하였다. 규제 세기는 Weight Decay 0.3~7에서 경계를 거의 바꾸지 않았다(4.1절, 4.2절).

○ 연구문제 2(가설 2 기각): 지연은 규칙의 대칭(등변군 크기)이 아니라 칸당 관찰 수로 설명되었다. 칸당 관찰 수가 약 0.4회 늘 때마다 지연이 약 절반으로 줄었고, 이 관계로 실험 전에 예측한 새 조건의 지연은 실측/예측 기하평균 1.11배였다. 학습 예제 수와 예제당 서로 다른 칸 수를 고정하면, 관찰 비율이 높을 때가 아니라 같은 칸이 여러 예제에 반복될 때(관찰 비율이 낮을 때) 지연이 짧아져 가설 2의 예측과 반대였다(4.3절). 규제 세기는 경계를 거의 바꾸지 않으면서 지연을 크게 바꾸었다(4.2절, 4.3절).

○ 연구문제 0(가설 0 부분 지지): 규제가 약하면(Weight Decay 1~3) 일반화한 모델도 대부분의 조건에서 학습 집합의 오답을 그대로 출력하여, 규칙의 학습과 오답의 암기가 공존하였다. 규제가 강하면(Weight Decay 7~10) 일반화 시점 전후에 오답이 교정되었으나, Weight Decay 15에서는 규칙 자체를 학습하지 못하였다. 본 실험 설정에서 규제 세기를 높였을 때 두 과제와 두 손실 모두에서 오답 교정이 관찰되었으며, 이는 CE에서 더 강한

규제가 필요하다는 [4]의 보고와 같은 방향이다. 입력이 곧 표 한 칸인 두 수 과제에서는 Weight Decay 3~5에서 오답이 유지된 채 평가 정확도가 낮아졌다. 같은 칸 오답은 흩어진 오답보다 평가 문제로 더 많이 전파되었고, 더 강한 규제에서 교정되었다(4.5절).

□ 5.2 논의

- 경계와 지연이 서로 다른 변수로 설명된 것은 두 양이 서로 다른 과정으로 정해지기 때문일 수 있다. 한 가지 해석은 모델이 연산 표를 칸 단위로 학습한다는 것이다. 모델은 관찰 칸을 먼저, 미관찰 칸을 나중에 맞혔고 오답도 칸 단위로 전파되었다(4.4절, 4.5절). 이 해석에서 지연이 긴 조건의 지연은 학습 초기의 예제 단위 암기에서 칸 단위 학습으로 전환되는 데 걸리는 시간이다. 규칙이 없는 무작위 표는 학습 초기부터 관찰 칸을 맞혔으므로(4.4절), 지연은 칸 단위 학습 자체가 어려워서가 아니라 예제 단위 암기에서 벗어나는 데 걸리는 시간으로 볼 수 있다. 같은 칸이 여러 예제에 반복되면 예제마다 따로 외우기보다 칸의 값을 학습하는 편이 유리해지므로, 반복 관찰이 지연을 줄인 결과와도 맞는다. 다만 같은 표에서 경계가 칸당 관찰 수가 아니라 학습 예제 수로 정해진 결과(4.1절)는 이 해석만으로 설명되지 않는다. 오답 방식에 따른 차이도 같은 틀로 설명할 수 있다. 흩어진 오답은 같은 칸의 정답 사례가 학습 집합에 남아 있어 이를 근거로 교정될 수 있지만, 같은 칸 오답은 다른 칸에서 배운 규칙을 적용해야만 교정되므로 더 강한 규제가 필요했을 수 있다.
- 다른 해석도 배제하지 못하였다. 관찰 비율을 낮추면 학습 집합에 나타나는 칸의 수 자체가 줄어 모델이 맞혀야 할 표의 범위가 작아지므로, 반복 관찰이 아니라 학습 대상의 축소가 지연을 줄였을 수 있다. 관계식의 지수가 1보다 작은 것은 표가 커져도 덧셈의 규칙성이 같기 때문일 수 있으나, 수의 범위에 따라 입력값의 표현이 학습되는 방식이 달라졌을 가능성도 있다. 오답 교정 역시 강한 규제가 오답 암기에 필요한 큰 가중치를 억제한 결과로 볼 수 있다. 내부 표현을 충분히 분석하지 않아 어느 설명이 맞는지는 확인하지 못하였다.
- 관계식의 계수는 모델 구조, 표의 구조, 규칙 합성 여부에 따라 달랐지만, 파라미터를 8배 늘려도 경계는 거의 같았다(4.2절). 따라서 필요한 데이터는 모델 용량보다 모델 구조와 과제의 복잡도에 좌우되는 것으로 보인다.
- 두 수 과제에서만 Weight Decay 3~5의 평가 정확도가 낮아진 것은, 입력이 곧 표 한 칸을 지정하여 오답 암기와 규칙 학습이 직접 충돌하기 때문일 수 있다.

□ 5.3 한계

- 과제와 모델의 범위: 결과는 2~4층 소형 Transformer와 인공적으로 만든 숫자 수열 과제에서 얻었다. 관계식은 기본 모델, Weight Decay 1, 연산 a+b, a+3b, n = 23~101에서 적합하였으며, 실제 언어 데이터와 대형 모델에 적용하려면 추가적인 연구가 필요하다.
- 경계 추정: 조건마다 3~10회만 반복하였고 경계를 인접한 격자값 사이에서 보간하였으므로, 반복 수와 격자 간격에 따른 불확실성이 있다(예: GPT형 디코더의 경계를 인접한 격자값 사이 임의의 위치에 두면 지수는 0.66~0.85). 또한 각 경계는 한 가지 데이터 분할에서 측정하여 분할에 따른 변동은 경계에 반영되지 않았다(경계 바로 위 조건에서 분

할을 바꾸면 일반화 비율 8/10 → 6/10, 4.3절). 또한 C는 학습과 평가에 나오지 않는 a = b 칸을 포함한 값이며, 실제로 나올 수 있는 칸 수(a+b는 n(n−1)/2)로 다시 적합하면 $N_0 \approx 3.3 \times C^{0.745}$로 지수가 1보다 작다는 결론은 같았다(이때 덧셈 두 번의 경계는 관계식의 약 2.3~2.5배).

○ 학습 step 수의 제한: 제한된 학습 기간으로 인해 Weight Decay 0.3의 n = 71에서는 경계의 상한값만 얻었다. n = 50의 덧셈 두 번은 학습 예제가 3만 개 이상이면 20만 step 동안 학습 정확도도 오르지 않는 경우가 많아 경계를 구하지 못하였다. 오답 유지도 20만 step까지만 관찰하였다. 오답 실험을 제외한 대부분의 실험은 일반화 후 1,000~5,000 step 뒤에 학습을 멈추었으므로, 일반화가 유지되는지는 오답 실험의 대조 학습(n = 50, 6만~20만 step)으로만 확인하였다.

□ 5.4 의의 및 활용 가능성

○ 본 탐구의 결과는 AI 모델을 학습시킬 때 학습 데이터의 양과 구성, 학습 상태의 판단에 대한 정량적 기준을 제공한다.

○ 학술적으로는 일반화에 필요한 학습 데이터의 양을 과제의 크기로 나타내는 관계식을 제시하였다. 선행연구는 일정량 이상의 학습 데이터가 필요하다고 보고하였으나([2], [3]), 본 탐구는 그 양을 연산 표의 칸 수에 대한 거듭제곱 관계식으로 나타냈고, 일반화 지연을 칸당 관찰 수로 실험 전에 예측하였다(실측/예측 기하평균 1.11배). 또한 약한 규제에서 오답 암기와 일반화가 공존하고 강한 규제에서 교정된다는 선행연구([4])의 결과를 수열 과제로 확장하여, 교정에 필요한 규제 세기가 오답의 배치(흩어진 오답, 같은 칸 오답)와 학습 예제 수에 따라 달라짐을 보였다.

○ 일반화에 필요한 학습 데이터의 양은 학습 전에 추정할 수 있으며, 데이터가 부족할 때 모델 크기를 늘리는 것만으로는 필요한 데이터가 크게 줄지 않는다. 관계식에 따르면 연산 표가 4배 커져도 필요한 학습 예제는 약 2.9배만 늘어나며, 도출 후 다시 측정한 조건에서도 실측 경계는 관계식 값의 0.89~1.13배였다(4.1절). 반면 검사한 두 모델 크기(파라미터 약 8배 차이)에서 경계는 3~12% 줄어드는 데 그쳤다(4.2절).

○ 일반화가 지연될 때는 학습 기간을 늘리기보다 학습 데이터를 소폭 늘리는 편이 효율적일 수 있다. 긴 지연은 경계 바로 위에서만 나타났으며, 5-순환 배선에서 학습 예제를 약 1.3배(768개 → 1,024개) 늘리자 지연(step 수)이 4,900 step에서 400 step으로 약 12배 짧아졌다(표 5). 지연의 길이는 칸당 관찰 수로 사전에 예측할 수 있었다(실측/예측 기하평균 1.11배, 4.3절).

○ 학습 데이터를 추가로 수집하지 않고 구성만 조정하여 학습 비용을 줄일 수 있다. 학습 예제 수(768개)를 고정하고 같은 칸이 여러 예제에 반복되도록 구성하자, 지연이 약 3~6배 짧아졌고 일반화 비율도 5/10에서 10/10으로 높아졌다(4.3절, 그림 6). 이는 데이터 수집 비용이 큰 경우 기존 데이터의 구성을 개선하는 근거가 된다.

○ 규제는 강할수록 좋은 것이 아니며 적절한 구간이 존재한다. Weight Decay 7에서는 경계를 크게 높이지 않으면서(Weight Decay 1의 0.93~1.20배) 두 방식의 조건 평균 오답 유지율이 모두 0.15 이하였다(학습 예제 2,048개 이상). 반면 Weight Decay 10 이상에서는

경계가 1.4~1.7배 높아지거나 학습이 붕괴하였고, 두 수 과제의 Weight Decay 3~5에서는 오답이 유지된 채 평가 정확도가 낮아졌다(4.2절, 4.5절).

- 학습 정확도만으로는 모델의 규칙 학습 여부와 학습 데이터의 정확성을 판단할 수 없다. 약한 규제(Weight Decay 1~3)에서는 일반화한 모델도 학습 데이터의 오답을 거의 그대로 출력하였다(4.5절). 따라서 모델의 성능은 학습에 사용하지 않은 평가 문제로 측정하고, 데이터 오류는 학습과 별도로 점검해야 한다. 특히 같은 계산에 반복된 오류는 평가 문제로 전파되었으므로(조건 평균 전파율 최대 0.99, 흩어진 오답은 0.08 이하) 우선 점검해야 한다.

6 참고문헌

[1] Power, A., Burda, Y., Edwards, H., Babuschkin, I., & Misra, V. (2022). Grokking: Generalization beyond overfitting on small algorithmic datasets. arXiv:2201.02177.

[2] Varma, V., Shah, R., Kenton, Z., Kramár, J., & Kumar, R. (2023). Explaining grokking through circuit efficiency. arXiv:2309.02390.

[3] Zhu, X., Fu, Y., Zhou, B., & Lin, Z. (2024). Critical data size of language models from a grokking perspective. arXiv:2401.10463.

[4] Doshi, D., Das, A., He, T., & Gromov, A. (2024). To grok or not to grok: Disentangling generalization and memorization on corrupted algorithmic datasets. ICLR 2024. arXiv:2310.13061.

[5] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. NeurIPS 2017.

[6] Nanda, N., Chan, L., Lieberum, T., Smith, J., & Steinhardt, J. (2023). Progress measures for grokking via mechanistic interpretability. ICLR 2023.

[7] Liu, Z., Michaud, E. J., & Tegmark, M. (2023). Omnigrok: Grokking beyond algorithmic data. ICLR 2023.

[8] Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. ICLR 2019.

[9] Thilak, V., Littwin, E., Zhai, S., Saremi, O., Paiss, R., & Susskind, J. (2022). The slingshot mechanism: An empirical study of adaptive optimizers and the grokking phenomenon. NeurIPS 2022 Workshop (HITY). arXiv:2206.04817.

[10] Kumar, T., Bordelon, B., Gershman, S. J., & Pehlevan, C. (2024). Grokking as the transition from lazy to rich training dynamics. ICLR 2024.

코드 및 데이터 실험 코드, 원자료, 그림 생성 코드: https://anonymous.4open.science/r/Grokking-6E17